


INTELIGENCIA ARTIFICIAL

De los Fundamentos a los LLMs y RAG

Temas: Fundamentos · Redes Neuronales · RNN · LSTM · GRU · Transformers · GenAI · LLMs · RAG



¿Qué es la Inteligencia Artificial?

La IA es la disciplina que busca crear sistemas capaces de realizar tareas que normalmente requieren inteligencia humana: razonamiento, aprendizaje, percepción y toma de decisiones.



Razonamiento

Resolver problemas
y tomar decisiones



Aprendizaje

Mejorar con datos
y experiencia



Percepción

Ver, escuchar y
entender el mundo



Lenguaje

Leer, escribir y
comunicarse

Componentes de la Inteligencia Artificial

Inteligencia Artificial

Sistemas que simulan inteligencia humana

Machine Learning

Aprendizaje automático desde datos

Deep Learning

Redes neuronales profundas

Generative AI

Creación de contenido nuevo



Datos

Combustible del aprendizaje



Algoritmos

Métodos de procesamiento



Modelos

Representaciones aprendidas



Computación

Hardware (GPU/TPU)

Tipos de Aprendizaje en Machine Learning



Supervisado

El modelo aprende de datos etiquetados.
Ejemplos: Clasificación, Regresión

Casos de uso:

- Spam detector
- Diagnóstico médico
- Precios de casas



No Supervisado

Encuentra patrones sin etiquetas.
Ejemplos: Clustering, Reducción dimensional

Casos de uso:

- Segmentación clientes
- Detección anomalías
- Compresión datos



Por Refuerzo

Aprende por recompensas y penalizaciones.
Ejemplos: Juegos, Robótica


Casos de uso:

- AlphaGo
- Robots industriales
- Trading automático


+ Semi-supervisado y Auto-supervisado: combinan técnicas para maximizar el uso de datos no etiquetados

Redes Neuronales Artificiales

Neurona Biológica



Neurona Artificial (Perceptrón)



$$\text{Fórmula: } \hat{y} = f(w_1x_1 + w_2x_2 + w_3x_3 + b)$$

Funciones de Activación Comunes

ReLU

$$\max(0, x)$$

Capas ocultas, evita vanishing gradient

Sigmoid

$$1/(1+e^{-x})$$

Salida binaria [0,1]

Tanh

$$(e^x - e^{-x}) / (e^x + e^{-x})$$


Datos centrados en 0

Softmax

$$e^{x_i} / \sum e^{x_j}$$

Clasificación multiclase

Deep Neural Networks (DNN)



Deep
= múltiples
capas
ocultas


Más capas
= mayor
capacidad
de
aprender
patrones
complejos

Propiedades: Backpropagation · Gradiente descendente · Representaciones jerárquicas · Transfer Learning

Redes Neuronales Recurrentes (RNN)

Diseñadas para datos secuenciales (texto, audio, series temporales)

RNN desplegada en el tiempo:



⚠ Problemas del RNN clásico

- **Vanishing Gradient:** gradientes desaparecen con secuencias largas
- **Memoria corta:** olvida dependencias lejanas


✅ Aplicaciones del RNN

- Traducción de textos básica
- Predicción de series temporales
- Reconocimiento de voz (primer uso)

Long Short-Term Memory (LSTM)

Inventado por Hochreiter & Schmidhuber (1997) — Soluciona el vanishing gradient con celdas de memoria

$C(t)$ Estado de Celda (memoria de largo plazo)



Por qué
LSTM
funciona:


✓
Memoria
long-term

✓ Control
fino de
q olvidar

✓
Gradiente
fluye sin
desaparecer

Gated Recurrent Unit (GRU)

Propuesto por Cho et al. (2014) — Versión simplificada y más eficiente del LSTM



GRU vs LSTM:

GRU: 2 puertas

LSTM: 3 puertas


GRU: más rápido

LSTM: más preciso

GRU: menos params

Similar desempeño


El Nacimiento de los Transformers



La Idea Central: Mecanismo de Atención (Self-Attention)


En lugar de procesar palabras secuencialmente (como RNN), los Transformers miran TODAS las palabras al mismo tiempo y calculan qué tan relevante es cada palabra para entender cada otra palabra — como un 'spotlight' que ilumina las conexiones importantes.

Arquitectura del Transformer



Mecanismo de Self-Attention (Atención)

Ejemplo: "El banco aprueba el préstamo"



¿Cómo funciona internamente?



Query (Consulta)

¿Qué estoy buscando?
"banco" pregunta por
su contexto



Key (Clave)

¿Qué tengo para ofrecer?
Cada palabra anuncia
su contenido



Value (Valor)

La información real
que se transmite si
hay match

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V$$

Inteligencia Artificial Generativa

IA que no solo analiza datos, sino que CREA contenido nuevo: texto, imágenes, audio, código, video...



GANs

Generative Adversarial
Networks (2014)

Generador vs Discriminador
en competencia

► **Imágenes realistas · Deepfakes**



VAEs

Variational
AutoEncoders (2013)

Comprimen y reconstruyen
datos en espacio latente

► **Síntesis de datos · Anomaly detection**



Diffusion

Modelos de Difusión
(2020-2022)

Aprenden a revertir
el proceso de ruido

► **DALL-E, Stable Diffusion · Midjourney**



LLMs

Large Language
Models (2018-hoy)

Transformers entrenados
en texto masivo

► **ChatGPT, Claude, · Gemini, Llama**

Large Language Models (LLMs)

Un LLM es un modelo de lenguaje con miles de millones de parámetros, entrenado sobre enormes corpus de texto usando la arquitectura Transformer, capaz de generar, resumir, traducir y razonar sobre texto.

Etapas de entrenamiento de un LLM:



Modelos destacados:

GPT-4

Claude 3

Gemini


Llama 3

Mistral

Command R

Retrieval-Augmented Generation (RAG)

Técnica que combina un LLM con una base de conocimiento externa para reducir alucinaciones y usar información actualizada




✗ Sin RAG (LLM solo)

- Alucinaciones frecuentes
- Información desactualizada
- Sin acceso a datos privados
- Costoso re-entrenar

✓ Con RAG

- Respuestas verificables con fuentes
- Información siempre actualizada
- Acceso a documentos privados
- Flexible y eficiente

El Viaje de la IA: De la Neurona al RAG



La IA continúa evolucionando — con modelos cada vez más capaces, eficientes y accesibles para todos



¡Gracias!

De las Redes Neuronales a los LLMs y RAG

IA

ML

DNN

RNN

LSTM

GRU

Transformers

Gen AI

LLMs

RAG