BSG Institute

Programa Certified AI-LLM Solution Architect

Curso Diseño de Infraestructura Escalable

Claves para construir plataformas eficientes y adaptables en la nube

www.bsginstitute.com

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data – IEBSchool
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Estudiante de Especialización en MLOps de la Universidad de Duke

andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

Resumen del Curso

- Introducción al curso y fundamentos del diseño de infraestructura escalable
- Requisitos de infraestructura para alojar modelos de lenguaje (LLMs)
- Plataformas de nube para soluciones de IA: AWS, Azure y GCP
- Servicios y herramientas de Azure para soluciones AI, LLM, RAG y Generative AI
- Servicios y capacidades de AWS para soluciones AI, LLM, RAG y Generative AI
- Servicios y capacidades de GCP para soluciones AI, LLM, RAG y Generative AI
- Ejemplo práctico: Desplegando una solución LLM en Microsoft Azure
- Recursos adicionales

BSG Institute

Introducción al curso y fundamentos del diseño de infraestructura escalable

BSG Institute

Presentación del curso y objetivos generales

- **Alcance del curso**

El curso abarca infraestructura para modelos de lenguaje en entornos cloud, desde conceptos básicos hasta aplicaciones avanzadas.

- **Competencias a desarrollar**

Se desarrollarán habilidades en gestión, implementación y optimización de modelos de lenguaje en la nube.

- **Aplicación práctica**

Los conocimientos se aplicarán para diseñar y mantener infraestructuras eficientes para modelos de lenguaje en la nube.

Importancia de la escalabilidad y alta disponibilidad en IA/LLM

- **Escalabilidad eficiente**

Los sistemas de inteligencia artificial requieren infraestructuras capaces de escalar dinámicamente para manejar incrementos significativos en la carga de trabajo sin comprometer la velocidad ni la calidad del procesamiento. Esto implica la capacidad de añadir recursos computacionales de manera rápida y flexible, asegurando un rendimiento óptimo incluso en situaciones de alta demanda.

- **Alta disponibilidad**

Es fundamental mantener una alta disponibilidad para garantizar que los sistemas de IA operen de forma ininterrumpida, minimizando tiempos de inactividad que puedan afectar la productividad o la experiencia del usuario. Esto incluye la implementación de mecanismos de redundancia, recuperación ante fallos y monitoreo constante para anticipar y resolver posibles problemas.

- **Soporte para cargas variables**

La infraestructura debe ser capaz de adaptarse eficientemente a las fluctuaciones en la demanda, soportando tanto picos inesperados como periodos de baja actividad. Esta flexibilidad asegura que los recursos se utilicen de manera óptima, evitando tanto la sobrecarga como el desperdicio de capacidad.

- **Seguridad robusta**

Proteger los datos y modelos de IA es esencial para mantener la integridad y confidencialidad de la información. La infraestructura debe incluir medidas avanzadas de seguridad, como cifrado de datos, control de accesos y auditorías regulares, para prevenir accesos no autorizados y posibles ataques cibernéticos.

- **Optimización del consumo energético**

Dado el alto consumo energético de los sistemas de IA, es importante contar con infraestructuras que optimicen el uso de energía para reducir costos y minimizar el impacto ambiental. Esto puede lograrse mediante el empleo de hardware eficiente, técnicas de gestión energética y estrategias de escalado inteligente.

Visión general de los modelos de lenguaje y sus requerimientos computacionales

Características técnicas de LLMs

Los modelos de lenguaje grandes poseen arquitecturas complejas y requieren gran capacidad de procesamiento para funcionar eficientemente.

Consumo de recursos

El entrenamiento y la inferencia de LLMs demandan altos recursos computacionales, incluyendo potencia de GPU y memoria avanzada.

Infraestructura especializada

Se requieren infraestructuras especializadas, como centros de datos dedicados, para soportar el entrenamiento e implementación de estos modelos.

BSG Institute

Requisitos de infraestructura para alojar modelos de lenguaje (LLMs)

Consideraciones de hardware y recursos para LLMs

- **Importancia de las GPUs**

Las GPUs son esenciales para acelerar el procesamiento paralelo, lo que permite manejar grandes volúmenes de datos y operaciones complejas de manera eficiente. Su capacidad para ejecutar miles de hilos simultáneamente mejora significativamente el rendimiento de los modelos de lenguaje de gran escala (LLMs), reduciendo los tiempos de entrenamiento y respuesta.

- **Rol de las CPUs**

Las CPUs desempeñan un papel fundamental en la gestión de tareas generales, incluyendo la coordinación y control de procesos que permiten la ejecución fluida de los LLMs. Además, son responsables de manejar operaciones secuenciales y administrar la comunicación entre diferentes componentes del sistema.

- **Memoria y dimensionamiento**

Contar con una memoria adecuada y bien dimensionada es crucial para manejar los grandes volúmenes de datos que requieren los LLMs. Esto incluye tanto la memoria RAM para procesos en tiempo real como la memoria dedicada de las GPUs para almacenar modelos y datos durante el entrenamiento y la inferencia.

- **Almacenamiento rápido y escalable**

El uso de sistemas de almacenamiento rápido, como discos SSD NVMe, facilita el acceso eficiente a grandes conjuntos de datos, lo que es vital durante el entrenamiento y despliegue de LLMs. Además, la escalabilidad del almacenamiento permite adaptarse al crecimiento de los modelos y bases de datos.

- **Optimización energética y térmica**

Dado el alto consumo energético de las GPUs y CPUs durante el entrenamiento de LLMs, es importante contar con soluciones de enfriamiento eficientes y estrategias para optimizar el consumo energético, garantizando la estabilidad y prolongando la vida útil del hardware.

- **Conectividad y ancho de banda**

Una conectividad de alta velocidad y un ancho de banda adecuado entre los distintos componentes del sistema son esenciales para evitar cuellos de botella en la transferencia de datos, especialmente en configuraciones distribuidas donde múltiples GPUs trabajan en conjunto.

- **Software y frameworks compatibles**

El soporte de software especializado y frameworks optimizados para el hardware disponible permite maximizar el rendimiento y facilitar el desarrollo de modelos, asegurando una integración eficiente y aprovechamiento de los recursos.

Gestión eficiente de almacenamiento y redes

- **Administración de grandes cantidades de datos**

Se emplean técnicas avanzadas y herramientas especializadas para gestionar de manera eficiente y organizada grandes volúmenes de información. Esto incluye el uso de bases de datos escalables, almacenamiento en la nube y sistemas de procesamiento distribuido que permiten optimizar la velocidad y precisión en el acceso y análisis de datos, garantizando la integridad y disponibilidad de la información.

- **Conectividad eficiente**

Es fundamental asegurar conexiones rápidas, estables y confiables entre los distintos componentes de la infraestructura tecnológica. Esto se logra mediante el diseño e implementación de redes robustas, la utilización de protocolos optimizados y la monitorización constante del rendimiento, con el fin de minimizar latencias, evitar interrupciones y soportar un alto volumen de tráfico.

- **Seguridad de redes**

Se desarrollan y aplican mecanismos de protección integrales para salvaguardar tanto la conectividad como la información frente a accesos no autorizados y posibles amenazas. Esto abarca la implementación de cortafuegos, sistemas de detección y prevención de intrusiones, cifrado de datos y políticas estrictas de control de acceso, garantizando así la confidencialidad, integridad y disponibilidad de los recursos.

Seguridad, compliance y gobernanza en infraestructura para LLMs

Protección de Datos

Es fundamental implementar medidas robustas y actualizadas para salvaguardar la información sensible que se maneja en entornos de inteligencia artificial basados en la nube. Esto incluye el uso de cifrado avanzado, control de accesos estrictos y auditorías periódicas para garantizar la confidencialidad, integridad y disponibilidad de los datos.

Cumplimiento Normativo

Adoptar políticas y regulaciones que aseguren el cumplimiento legal es esencial para operar infraestructuras de modelos lingüísticos grandes. Esto implica mantenerse al día con las normativas internacionales, nacionales y sectoriales, además de implementar procesos que faciliten la trazabilidad y la transparencia en el manejo de datos.

Gobernanza de Infraestructura

Establecer prácticas recomendadas para gestionar y supervisar la infraestructura de IA de manera responsable y segura es clave para el éxito y la sostenibilidad. Esto abarca la definición clara de roles y responsabilidades, la monitorización continua del rendimiento y la seguridad, así como la implementación de planes de contingencia ante posibles incidentes.

Optimización de Recursos

Es necesario optimizar el uso de recursos computacionales y energéticos para garantizar la eficiencia operativa y reducir el impacto ambiental. La implementación de técnicas de escalado dinámico, uso de hardware eficiente y la adopción de algoritmos optimizados contribuyen a maximizar el rendimiento sin comprometer la calidad.

Transparencia y Explicabilidad

Fomentar la transparencia en los procesos y resultados de los modelos lingüísticos facilita la confianza y comprensión por parte de los usuarios y reguladores. Esto incluye desarrollar mecanismos que permitan explicar cómo y por qué se toman ciertas decisiones, así como documentar claramente los procesos involucrados.

Capacitación y Concienciación

Promover la formación continua y la concienciación entre los equipos que gestionan y desarrollan infraestructuras de IA es indispensable para mantener altos estándares de seguridad y ética. La educación sobre mejores prácticas, riesgos y novedades tecnológicas contribuye a fortalecer la cultura organizacional y a mitigar posibles vulnerabilidades.

BSG Institute

Plataformas de nube para soluciones de IA: AWS, Azure y GCP

Comparativa de servicios cloud: ventajas y desventajas de cada plataforma

Costos de Servicios Cloud

Comparar los costos es fundamental para seleccionar la plataforma que mejor se adapte a las necesidades y al presupuesto de cada organización. Es importante considerar no solo el precio inicial, sino también los costos ocultos y escalables que puedan surgir con el tiempo.

Disponibilidad y Fiabilidad

Evaluar la disponibilidad garantiza la continuidad del servicio y minimiza interrupciones, mientras que la fiabilidad de la infraestructura cloud asegura un rendimiento estable y seguro para las aplicaciones y datos críticos.

Ecosistema y Soporte para IA

Las plataformas ofrecen distintos ecosistemas tecnológicos y capacidades de inteligencia artificial que facilitan la integración de soluciones avanzadas, permitiendo a las empresas innovar y optimizar sus procesos.

Seguridad y Cumplimiento Normativo

Es esencial que la plataforma cloud cuente con robustas medidas de seguridad para proteger los datos, así como el cumplimiento de normativas locales e internacionales que aseguren la privacidad y el manejo adecuado de la información.

Escalabilidad y Flexibilidad

La capacidad de escalar recursos según la demanda y la flexibilidad para adaptar servicios a diferentes cargas de trabajo son aspectos clave para garantizar eficiencia y reducir costos operativos a largo plazo.

Comparativa de servicios cloud: ventajas y desventajas de cada plataforma

Criterio	AWS (Amazon Web Services)	Microsoft Azure	Google Cloud Platform (GCP)
Costos de Servicios Cloud	• **Ventajas:** Amplia variedad de instancias con precios granulares; descuentos por uso reservado (Savings Plans); gran ecosistema FinOps (Cost Explorer, Budgets) • **Desventajas:** Costos de salida de datos altos; estructura compleja de precios; sobrecostos al usar múltiples servicios integrados.	• **Ventajas:** Modelo de precios competitivo en servicios PaaS y AI; descuentos por uso sostenido; integración con licencias Microsoft existentes (EA, CSP, Hybrid Benefit). • **Desventajas:** Costos variables en servicios de red y almacenamiento; requiere optimización activa para workloads GPU/LLM.	• **Ventajas:** Precios transparentes; descuentos automáticos por uso sostenido; facturación sencilla para workloads de AI y Big Data. • **Desventajas:** Menor flexibilidad en descuentos empresariales; costos variables en regiones premium.
Disponibilidad y Fiabilidad	• **Ventajas:** 100+ zonas de disponibilidad; SLA líder (hasta 99.99%); madurez operativa y estabilidad probada. • **Desventajas:** Mayor latencia en regiones no principales; complejidad al gestionar redundancia multi-región.	• **Ventajas:** SLA robustos (99.95%+); integración nativa con Active Directory y ecosistemas corporativos; redundancia geográfica bien soportada. • **Desventajas:** Algunas regiones menos consistentes en latencia; dependencia del ecosistema Microsoft.	• **Ventajas:** Red global privada de alta velocidad (la misma de YouTube/Google Search); tiempos de recuperación rápidos; excelente balanceo global (Cloud Load Balancing). • **Desventajas:** Menor cobertura regional que AWS/Azure.
Ecosistema y Soporte para IA	• **Ventajas:** SageMaker, Bedrock, Titan Models, integración con Hugging Face; soporte amplio para PyTorch, TensorFlow, LlamaIndex, LangChain. • **Desventajas:** Complejidad en despliegues multi-modelo; integración no tan fluida con Microsoft Copilot u Office.	• **Ventajas:** Azure OpenAI Service, Azure Machine Learning, Cognitive Services; integración directa con Copilot, Power Platform y M365; excelente soporte empresarial para LLMOps. • **Desventajas:** Acceso a modelos OpenAI sujeto a disponibilidad regional y aprobación previa.	• **Ventajas:** Vertex AI, PaLM 2 / Gemini APIs, AutoML, BigQuery ML; ecosistema optimizado para pipelines de datos y ML. • **Desventajas:** Algunos servicios avanzados aún en preview o limitados regionalmente.
Seguridad y Cumplimiento Normativo	• **Ventajas:** Amplio cumplimiento (ISO, SOC, GDPR, FedRAMP); IAM granular (AWS Identity Center, KMS, Macie). • **Desventajas:** Configuración compleja; gestión manual de roles puede ser propensa a errores.	• **Ventajas:** Cumplimiento corporativo extenso (HIPAA, GDPR, ISO, SOC); integración nativa con Azure AD, Defender for Cloud y Sentinel. • **Desventajas:** La configuración inicial puede ser densa para pequeñas empresas.	• **Ventajas:** Cifrado predeterminado en tránsito/reposo; IAM simple y centralizado; cumplimiento ISO/PCI/SOC. • **Desventajas:** Menos herramientas nativas de auditoría comparadas con AWS/Azure.
Escalabilidad y Flexibilidad	• **Ventajas:** Escalado automático granular; soporte para arquitecturas híbridas (Outposts, EKS Anywhere); enorme catálogo de instancias GPU (P4d, G5, Trainium, Inferentia). • **Desventajas:** Curva de aprendizaje pronunciada y administración avanzada requerida.	• **Ventajas:** Escalabilidad elástica integrada con AKS, VM Scale Sets, Logic Apps; soporte híbrido completo (Arc, Stack HCI). • **Desventajas:** Algunos servicios serverless con límites más conservadores que AWS/GCP.	• **Ventajas:** Escalabilidad instantánea en Compute Engine, GKE Autopilot y Cloud Run; infraestructura altamente flexible y ligera. • **Desventajas:** Falta de integración híbrida tan robusta como Azure Arc o AWS Outposts.

Comparativa de servicios cloud: ventajas y desventajas de cada plataforma

Conclusiones Estratégicas

- **AWS** → Ideal para organizaciones que requieren **máxima madurez operativa**, variedad de servicios y control detallado de costos.

- **Azure** → Preferida por entornos **corporativos, gubernamentales y educativos**, con fuerte integración a Microsoft 365 y ecosistemas de datos empresariales.

- **GCP** → Excelente para **workloads de datos, IA nativa y proyectos de investigación**, gracias a su simplicidad, precio transparente y herramientas de machine learning avanzadas.

Herramientas clave: Kubernetes, Docker y sus integraciones en la nube

Orquestación de Contenedores

Kubernetes es una plataforma avanzada que facilita la orquestación y gestión automática de contenedores en entornos complejos de nube. Permite escalar aplicaciones de manera eficiente, administrar el ciclo de vida de los contenedores y asegurar la alta disponibilidad mediante la distribución inteligente de las cargas de trabajo.

Despliegue con Docker

Docker es una herramienta que permite empaquetar aplicaciones junto con todas sus dependencias en contenedores portátiles y ligeros. Esto garantiza que las aplicaciones se ejecuten de manera consistente en cualquier entorno, facilitando un despliegue rápido y fiable, además de simplificar el desarrollo y las pruebas.

Integración en la Nube

Estas tecnologías se integran perfectamente con plataformas en la nube como AWS, Google Cloud y Microsoft Azure, permitiendo el soporte de aplicaciones de inteligencia artificial que requieren escalabilidad y flexibilidad. La integración asegura que los recursos se asignen de manera óptima según la demanda y facilita la gestión remota.

Otras Herramientas Relevantes

- **Helm:** Un gestor de paquetes para Kubernetes que simplifica la instalación y gestión de aplicaciones complejas mediante gráficos predefinidos.
- **Prometheus:** Sistema de monitoreo y alerta que recopila métricas en tiempo real para garantizar el rendimiento y la salud de las aplicaciones y contenedores.
- **Istio:** Plataforma de servicio que proporciona control de tráfico, seguridad y observabilidad para aplicaciones desplegadas en Kubernetes, mejorando la gestión del tráfico entre microservicios.

Docker en IA y despliegue

Portabilidad y Escalabilidad

Docker facilita la portabilidad y escalabilidad de aplicaciones al permitir su ejecución en cualquier entorno compatible con contenedores.

Reproducibilidad en IA

Permite empaquetar modelos, scripts y dependencias, asegurando que los experimentos de IA sean fácilmente reproducibles y consistentes.

Despliegue e Integración Continua

Es fundamental para desplegar soluciones de IA, LLM, RAG y GenAI en producción, facilitando la integración continua y actualizaciones fáciles.

Kubernetes en IA y GenAI

BSG Institute

- **Escalabilidad y Gestión Eficiente**

Kubernetes ofrece una plataforma robusta que permite escalar aplicaciones de inteligencia artificial de manera dinámica según la demanda, optimizando el uso de recursos computacionales y reduciendo costos operativos. Además, su arquitectura facilita la gestión centralizada y el monitoreo continuo, lo que contribuye a mantener un rendimiento óptimo y una alta disponibilidad.

- **Automatización de Despliegues**

Mediante Kubernetes, los despliegues de modelos de lenguaje grande (LLM), recuperación basada en grafos (RAG) y generación de inteligencia artificial (GenAI) se pueden automatizar completamente. Esto garantiza que las aplicaciones estén siempre actualizadas y disponibles, minimizando el tiempo de inactividad y permitiendo una recuperación rápida en caso de fallos.

- **Integración Continua y Entrega**

La plataforma facilita la implementación de pipelines de integración y entrega continua (CI/CD), permitiendo que los equipos de desarrollo implementen actualizaciones y mejoras de manera ágil, manteniendo la seguridad y la estabilidad del sistema.

- **Optimización de Recursos y Costos**

Kubernetes permite asignar recursos de manera inteligente mediante la orquestación de contenedores, lo que se traduce en una utilización eficiente del hardware y una reducción significativa de costos asociados a infraestructuras infrautilizadas.

- **Alta Disponibilidad y Recuperación ante Desastres**

La arquitectura distribuida de Kubernetes asegura que las aplicaciones de IA permanezcan disponibles incluso ante fallos de componentes individuales, gracias a mecanismos automáticos de replicación y recuperación.

- **Seguridad y Control de Acceso**

Kubernetes integra herramientas avanzadas para gestionar la seguridad, incluyendo políticas de acceso basadas en roles (RBAC), aislamiento de pods y gestión de secretos, lo que garantiza que las aplicaciones de inteligencia artificial operen en entornos protegidos y conformes con normativas.

Integración GitHub, Docker y Kubernetes

Colaboración y Control de Versiones

GitHub es una plataforma esencial para el trabajo en equipo en proyectos de inteligencia artificial, ya que permite gestionar eficazmente las versiones del código fuente. Esto facilita la colaboración continua entre desarrolladores, permitiendo realizar seguimiento de cambios, resolver conflictos y mantener un historial claro del desarrollo, lo que garantiza la integridad y calidad del proyecto.

Despliegue Reproducible con Docker

Docker ofrece una solución para empaquetar modelos de inteligencia artificial junto con todas sus dependencias y configuraciones en contenedores portátiles. Esto asegura que los despliegues sean reproducibles y consistentes, independientemente del entorno en el que se ejecuten, evitando problemas relacionados con incompatibilidades o configuraciones erróneas.

Orquestación y Escalabilidad con Kubernetes

Kubernetes es una herramienta clave para la gestión de contenedores en proyectos de MLOps, ya que automatiza el despliegue, la orquestación y la escalabilidad de las aplicaciones. Permite distribuir cargas de trabajo de manera eficiente, gestionar el estado de los contenedores y escalar recursos automáticamente según la demanda, optimizando el rendimiento y la disponibilidad.

Automatización con CI/CD

La integración continua y el despliegue continuo (CI/CD) son prácticas fundamentales para automatizar las pruebas y el lanzamiento de modelos de inteligencia artificial. Esto reduce errores humanos, acelera el ciclo de desarrollo y garantiza que las implementaciones sean seguras, estables y eficientes, manteniendo la calidad del software en todo momento.

Monitoreo y Gestión de Modelos

Implementar herramientas de monitoreo permite supervisar el rendimiento de los modelos de inteligencia artificial en producción, detectando desviaciones o degradación en su comportamiento. Esto facilita la gestión proactiva, permitiendo realizar ajustes o reentrenamientos a tiempo para mantener la eficacia y precisión de los modelos a lo largo del tiempo.

BSG Institute

Servicios y herramientas de Azure para soluciones AI, LLM, RAG y Generative AI

Servicios administrados de Azure para IA y modelos de lenguaje

Azure Cognitive Services
Plataforma que ofrece APIs inteligentes para integrar capacidades avanzadas de visión, lenguaje y toma de decisiones en aplicaciones, permitiendo mejorar la interacción y experiencia del usuario mediante inteligencia artificial.

Azure OpenAI Service
Servicio especializado para desplegar y administrar modelos avanzados de lenguaje natural en la nube, garantizando seguridad y escalabilidad para aplicaciones que requieren procesamiento de lenguaje a gran escala.

Recursos para administración
Conjunto de herramientas y recursos que facilitan la gestión, monitoreo y optimización continua de modelos de IA en Azure, asegurando un rendimiento eficiente y control total sobre los despliegues.

Azure Bot Service
Permite crear, conectar y gestionar bots inteligentes que interactúan con usuarios a través de múltiples canales, mejorando la automatización y atención personalizada.

Azure Machine Learning
Plataforma integral para construir, entrenar y desplegar modelos de aprendizaje automático con soporte para colaboración, automatización y administración de ciclo de vida de modelos.

Azure Form Recognizer
Servicio que utiliza IA para extraer información estructurada de documentos y formularios, acelerando procesos de captura y análisis de datos con alta precisión.

Integración de Azure Cognitive Services y Azure OpenAI

- **Servicios Cognitivos de Azure**

Azure Cognitive Services proporciona un conjunto integral de APIs y herramientas diseñadas para facilitar el procesamiento y la comprensión avanzada del lenguaje natural. Estas capacidades permiten a las aplicaciones interpretar, analizar y extraer significado de textos en múltiples idiomas, lo que resulta esencial para tareas como el análisis de sentimientos, reconocimiento de entidades, traducción automática y análisis de texto.

- **Azure OpenAI para generación de lenguaje**

Azure OpenAI ofrece acceso a modelos generativos basados en inteligencia artificial, capaces de producir texto coherente, creativo y contextualizado. Estos modelos permiten la generación automática de contenido, respuestas inteligentes en chatbots, asistencia en redacción y otras aplicaciones que requieran interacción natural y fluida con los usuarios.

- **Integración avanzada**

La combinación estratégica de los Servicios Cognitivos de Azure con Azure OpenAI permite desarrollar soluciones robustas que no solo comprenden el lenguaje natural de manera profunda, sino que también generan respuestas y contenido con alta precisión y relevancia. Esta integración potencia aplicaciones en áreas como atención al cliente, educación, análisis de datos y más, mejorando la experiencia del usuario y optimizando procesos mediante inteligencia artificial avanzada.

Opciones de almacenamiento, seguridad y despliegue especializado para soluciones GEN AI/RAG

Almacenamiento Seguro en la Nube
Azure proporciona soluciones avanzadas de almacenamiento que garantizan la seguridad confidencialidad de los datos sensibles mediante cifrado de última generación y múltiples capas de protección. Estas medidas son esenciales para aplicaciones de Inteligencia Artificial Generativa (GEN AI) y Recuperación Autónoma Guiada (RAG), donde la integrid y privacidad de la información son prioritarias.

Escalabilidad Flexible
Las plataformas en la nube ofrecen una escalabilidad dinámica y automática que permite ajustar los recursos informáticos en tiempo real según la demanda fluctuante de las aplicaciones basadas en inteligencia artificial. Esto asegura un rendimiento óptimo sin incurrir en costos innecesarios, facilitando la gestión eficiente de cargas de trabajo variables.

Despliegue Adaptado
Los servicios especializados de Azure permiten diseñar y ejecutar despliegues altamente personalizados para soluciones GEN AI y RAG, optimizando tanto el rendimiento como la eficiencia operativa. Esta adaptabilidad facilita la integración con sistemas existentes y la implementación de arquitecturas específicas que maximizan el potencial de las aplicacior inteligentes.

Opciones de almacenamiento, seguridad y despliegue especializado para soluciones GEN AI/RAG

Categoría	AWS	Microsoft Azure	Google Cloud Platform (GCP)
Almacenamiento de Datos / Embeddings	• **Amazon S3:** almacenamiento masivo de datos estructurados y no estructurados con alta durabilidad (11x9). • **Amazon OpenSearch / Kendra:** almacenamiento e indexación semántica y búsqueda de embeddings RAG. • **DynamoDB:** baja latencia para metadata y chat histories. • **Amazon Neptune:** base de conocimiento en grafo para contextos de LLM. • **Ventajas:** integración nativa con SageMaker y Bedrock. • **Desventajas:** costos adicionales por consultas semánticas intensivas.	• **Azure Blob Storage:** almacenamiento escalable de datos y documentos para contextos RAG. • **Azure Cognitive Search + CosmosDB:** vector storage e indexación semántica nativa con integración OpenAI. • **Azure Data Lake Storage Gen2:** para pipelines ETL/ELT y datasets masivos de entrenamiento. • **Ventajas:** integración directa con Azure OpenAI y Cognitive Services. • **Desventajas:** costos variables de consultas en Cognitive Search.	• **Cloud Storage:** equivalente a S3/Blob con integración directa a Vertex AI y Dataflow. • **Vertex AI Vector Search:** motor de búsqueda de embeddings totalmente gestionado y escalable. • **BigQuery / Bigtable:** para almacenamiento analítico y metadatos contextuales. • **Ventajas:** rendimiento superior para búsquedas vectoriales masivas. • **Desventajas:** algunas funciones de Vector Search aún en evolución (fine-tuning avanzado).
Seguridad y Cumplimiento	• **IAM / KMS / PrivateLink / VPC Endpoints:** control granular de acceso, cifrado en tránsito y en reposo, redes privadas sin exposición pública. • **Amazon GuardDuty / Macie:** detección de amenazas y protección de datos sensibles. • **AWS Bedrock Governance:** políticas de uso responsable y monitoreo de contenido LLM. • **Ventajas:** madurez y amplitud de certificaciones (FedRAMP, HIPAA, GDPR). • **Desventajas:** configuración IAM compleja.	• **Azure Active Directory / Entra ID:** identidad centralizada, RBAC, y soporte para MFA y PIM. • **Azure Key Vault / Defender for Cloud / Private Link:** gestión de secretos, protección de endpoints y cumplimiento continuo. • **Content Safety y Responsible AI Service:** filtros y moderadores para uso ético de LLMs. • **Ventajas:** cumplimiento corporativo muy sólido (ISO, GDPR, HIPAA, NIST). • **Desventajas:** requiere gobernanza bien estructurada para entornos multi-tenant.	• **Cloud IAM / KMS / VPC Service Controls:** aislamiento de datos, control de acceso y encriptación granular. • **Security Command Center:** supervisión unificada de vulnerabilidades y amenazas. • **Vertex AI Trust and Safety Layer:** controles de contenido y gobernanza de modelos. • **Ventajas:** integración fluida con políticas Zero Trust y cifrado end-to-end. • **Desventajas:** políticas menos flexibles en entornos híbridos.
Despliegue Especializado (Model Serving / RAG Pipelines)	• **Amazon SageMaker / Bedrock / ECS / EKS:** soporte completo para inferencia distribuida y pipelines RAG. • **EKS con LangChain + OpenSearch:** arquitectura típica para GenAI con memoria contextual. • **Inferentia / Trainium:** chips optimizados para inferencia LLM. • **Ventajas:** soporte nativo para frameworks Hugging Face, LangChain y Ray. • **Desventajas:** configuración inicial más compleja.	• **Azure Machine Learning / Azure OpenAI Service / AKS:** despliegue gestionado de modelos LLM con endpoints autoscalables. • **Cognitive Search + CosmosDB + Functions:** stack RAG completo (vector search + retrieval + reasoning). • **Ventajas:** integración nativa con Copilot y Power Platform; CI/CD vía GitHub Actions o ADO. • **Desventajas:** latencia algo superior en regiones saturadas.	• **Vertex AI / Cloud Run / GKE Autopilot:** despliegue serverless o gestionado de modelos; escalado automático por carga. • **Vertex AI Search + Generative AI Studio:** pipeline RAG preconfigurado. • **Ventajas:** rápido time-to-market y UI intuitiva para orquestación de flujos RAG. • **Desventajas:** menor control granular sobre hardware subyacente.

Opciones de almacenamiento, seguridad y despliegue especializado para soluciones GEN AI/RAG

Insights Arquitectónicos Detallados

Para proyectos empresariales integrados (Copilot, M365, SharePoint): Azure se posiciona como la opción más eficiente debido a su profunda integración nativa con Microsoft 365, que facilita la colaboración y productividad. Además, su compatibilidad con Cognitive Search y OpenAI Service permite implementar soluciones inteligentes de búsqueda y procesamiento de lenguaje natural, optimizando flujos de trabajo y mejorando la experiencia del usuario.

Para proyectos de I+D y modelos de lenguaje personalizados (LLM): Google Cloud Platform (GCP) sobresale por su infraestructura avanzada orientada a la gestión y análisis de grandes volúmenes de datos. Herramientas como Vertex AI y BigQuery ML proporcionan capacidades potentes para el entrenamiento, despliegue y monitoreo de modelos de machine learning personalizados. Asimismo, la integración con modelos de última generación como PaLM y Gemini potencia la creación de soluciones innovadoras y escalables.

Para escalas industriales o productos SaaS: Amazon Web Services (AWS) ofrece una infraestructura distribuida de alta disponibilidad, diseñada para soportar cargas de trabajo críticas y en constante crecimiento. Su capacidad de autoscaling en GPU y TPU garantiza el rendimiento óptimo en aplicaciones intensivas en cómputo, mientras que la compatibilidad con múltiples frameworks de machine learning facilita la flexibilidad y adaptabilidad en el desarrollo de soluciones a gran escala.

Recomendación Estratégica para Arquitectos AI

Escenario	Plataforma Ideal	Stack Recomendado
RAG empresarial y LLMs integrados en Microsoft 365	**Azure**	Azure OpenAI + Cognitive Search + CosmosDB + AKS
Despliegue de modelos open source (Llama2, Mistral, Falcon) en producción	**AWS**	Bedrock + EKS + OpenSearch + SageMaker
Laboratorios de GenAI con datasets masivos y pipelines autoML	**GCP**	Vertex AI + BigQuery + Cloud Storage + Vector Search

BSG Institute

Servicios y capacidades de AWS para soluciones AI, LLM, RAG y Generative AI

Servicios administrados de AWS para IA y modelos de lenguaje

Entrenamiento de modelos con SageMaker: Amazon SageMaker ofrece una plataforma integral para entrenar modelos de lenguaje a gran escala, aprovechando infraestructura en la nube que garantiza eficiencia y rapidez. Permite la configuración de entornos personalizados, el uso de algoritmos optimizados y la integración con conjuntos de datos diversos para mejorar la precisión y el rendimiento de los modelos.

Despliegue con AWS Lambda: AWS Lambda posibilita la implementación de modelos de lenguaje en un entorno sin servidor, lo que facilita la ejecución bajo demanda sin necesidad de administrar servidores. Esta capacidad permite una escalabilidad automática y una reducción significativa de costos, ideal para aplicaciones que requieren respuestas rápidas y flexibles.

Gestión simplificada de modelos: Los servicios de AWS proporcionan herramientas avanzadas para la gestión de modelos, incluyendo monitoreo en tiempo real, alertas automáticas y escalado dinámico según la demanda. Esto asegura que los modelos funcionen de manera óptima y se adapten a variaciones en el tráfico o en los requisitos del sistema.

Integración con AWS Glue para preparación de datos: AWS Glue facilita la extracción, transformación y carga (ETL) de grandes volúmenes de datos, lo que es fundamental para preparar conjuntos de datos limpios y estructurados para el entrenamiento de modelos de lenguaje. Esta integración optimiza el flujo de trabajo y mejora la calidad de los datos.

Almacenamiento seguro y escalable con Amazon S3: Amazon S3 ofrece un almacenamiento robusto y escalable para guardar grandes cantidades de datos y artefactos de modelos. Además, proporciona controles de acceso avanzados y cifrado para proteger la información sensible durante todo el ciclo de vida del modelo.

Automatización de pipelines con AWS Step Functions: AWS Step Functions permite diseñar y automatizar pipelines de machine learning, coordinando tareas como la ingesta de datos, entrenamiento, validación y despliegue. Esta automatización mejora la eficiencia operativa y reduce los errores humanos en procesos complejos.

Uso de Amazon Comprehend para análisis de texto: Amazon Comprehend es un servicio de procesamiento de lenguaje natural que ayuda a extraer información valiosa de textos, como sentimientos, entidades y temas. Su integración con modelos personalizados en SageMaker permite enriquecer las aplicaciones con funcionalidades avanzadas de comprensión del lenguaje.

Opciones en AWS

Gestión de datos

AWS ofrece diversas opciones de almacenamiento para manejar grandes volúmenes de datos de forma eficiente y segura.

Seguridad de infraestructura

La plataforma AWS integra medidas robustas para proteger la infraestructura y garantizar la confidencialidad de los datos.

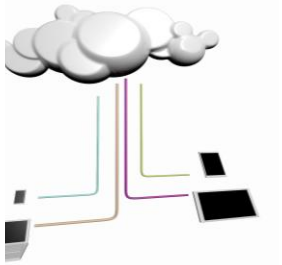

Escalabilidad de aplicaciones

AWS facilita la escalabilidad dinámica para aplicaciones de inteligencia artificial, permitiendo crecimiento sin interrupciones.

Integración con herramientas open source y despliegue de soluciones LLM/RAG/GEN AI en AWS

Integración con tecnologías open source

AWS facilita la integración con herramientas open source para mejorar el desarrollo de soluciones avanzadas.

Soluciones generativas y de recuperación

Potencia soluciones generativas y recuperación aumentada para optimizar la experiencia tecnológica.

Integración con herramientas open source y despliegue de soluciones LLM/RAG/GEN AI en AWS

Área	Servicios AWS Relevantes	Integraciones Open-Source y Frameworks Compatibles	Descripción Técnica / Casos de Uso Clave
Orquestación y Frameworks de RAG/LLM	**Amazon Bedrock**, **SageMaker**, **EKS (Elastic Kubernetes Service)**, **Lambda**	• **LangChain** (retrieval orchestration y agent pipelines) • **LlamaIndex** (data connectors y embeddings contextuales) • **Semantic Kernel** (via API Gateway / SDK) • **Hugging Face Transformers** (inference y fine-tuning) • **Ray** (orquestación distribuida)	AWS permite construir pipelines RAG modulares con Bedrock como capa de inferencia y EKS/Lambda para la orquestación. LangChain y LlamaIndex se integran directamente con API Gateway y servicios RESTful. Ideal para arquitecturas serverless o contenedorizadas.
Modelos y Repositorios de LLMs	**Amazon Bedrock**, **SageMaker JumpStart**, **ECR (Elastic Container Registry)**	• **Hugging Face Hub** (modelos open-source integrados en SageMaker JumpStart) • **PyTorch / TensorFlow / JAX** (frameworks nativos) • **Triton Inference Server**, **vLLM** para serving personalizado • **Transformers / PEFT / LoRA** (fine-tuning ligero)	SageMaker JumpStart y Bedrock ofrecen modelos foundation (Titan, Claude, Llama3, Mistral, Falcon) junto con soporte a Hugging Face. Permite subir modelos custom vía ECR o TorchServe.
Almacenamiento y Recuperación (RAG Data Layer)	**Amazon S3**, **DynamoDB**, **OpenSearch Service**, **Neptune**, **Kendra**	• **Pinecone**, **Weaviate**, **Milvus**, **FAISS** (vía SDK o EC2/EKS) • **LangChain VectorStore** integrado con OpenSearch y Kendra • **Elastic Search DSL y Retriever Chains**	Para Retrieval-Augmented Generation (RAG), AWS soporta arquitecturas híbridas: almacenamiento en S3 + embeddings en OpenSearch (vector search) + contexto semántico en Kendra. Puede escalarse horizontalmente con autoscaling groups.
Entrenamiento, Fine-tuning e Inferencia	**SageMaker Training Jobs**, **SageMaker Endpoint**, **EKS + EC2 GPU Instances (P4d, G5, Inf2)**	• **Hugging Face Transformers**, **Deepspeed**, **Accelerate**, **PEFT / LoRA**, **TensorRT / FasterTransformer** • **vLLM / TGI (Text Generation Inference)**	Permite entrenamiento distribuido con Deepspeed o Accelerate, y despliegue optimizado con Inferentia2 o Trainium. TGI o vLLM pueden correr sobre EKS o SageMaker Endpoints. Escalabilidad automática según tráfico de inferencia.
Integración CI/CD y MLOps / LLMOps	**CodePipeline**, **CodeBuild**, **SageMaker Pipelines**, **Step Functions**	• **MLflow**, **DVC**, **Kubeflow on EKS**, **Airflow** • **GitHub Actions** / **Jenkins** / **Terraform** (Infra as Code) • **Weights & Biases**, **Neptune ML**, **Metaflow**	Permite versionar modelos y datos, ejecutar pipelines CI/CD automáticos y gobernar ciclos de entrenamiento e inferencia. Integración directa con IaC (CloudFormation/Terraform) y monitoreo continuo.
Despliegue de Aplicaciones LLM / APIs GenAI	**ECS / EKS / Lambda / API Gateway / App Runner**	• **Flask / FastAPI / LangServe** (para endpoints REST) • **Docker Compose / Helm Charts / ArgoCD** (para despliegue en Kubernetes) • **AWS CDK / Terraform** (infraestructura reproducible)	El despliegue puede ser **serverless** (Lambda + API Gateway) o **contenedorizado** (EKS/ECS). LangServe y FastAPI son patrones comunes para APIs RAG o chatbots con LangChain.
Observabilidad, Costos y Seguridad	**CloudWatch**, **CloudTrail**, **GuardDuty**, **Macie**, **KMS**, **IAM**, **Bedrock Guardrails**	• **Prometheus / Grafana on EKS**, **OpenTelemetry SDKs** • **AWS X-Ray**, **Datadog**, **ELK Stack**	AWS provee observabilidad avanzada para inferencias, trazas y métricas LLM. Bedrock Guardrails agrega filtros de contenido, control de salida y monitoreo de comportamiento ético del modelo.
Despliegue Multimodal y Avanzado (opcional)	**Bedrock Agents**, **Rekognition**, **Transcribe**, **Comprehend**, **Polly**, **Textract**	**OpenCV / Tesseract / SpeechBrain / Whisper**	Permite extender soluciones GenAI hacia visión, voz y texto con APIs multimodales, integrando pipelines con LangChain Agents y Bedrock multimodal.

Ventajas estratégicas de AWS en Integraciones GenAI

Aspecto	Fortalezas Clave
Open Source	Integraciones completas con Hugging Face, LangChain, LlamaIndex, Ray, Deepspeed, Triton.
Escalabilidad	EKS/ECS con autoescalado GPU y despliegue multinodo optimizado.
Seguridad y Cumplimiento	IAM granular, KMS, Bedrock Guardrails, PrivateLink, cumplimiento FedRAMP/ISO/GDPR.
Rendimiento	Instancias P4d/G5 e Inferentia2 con soporte nativo para entrenamiento e inferencia LLM.
Gobernanza	SageMaker Pipelines y Step Functions permiten trazabilidad, auditoría y control total del ciclo de vida.

BSG Institute

Servicios y capacidades de GCP para soluciones AI, LLM, RAG y Generative AI

Servicios administrados de GCP para IA y modelos de lenguaje

En Google Cloud Platform (GCP), los servicios administrados de inteligencia artificial han evolucionado mucho, especialmente desde 2024 con la integración de Gemini (antes PaLM 2) y las mejoras en Vertex AI.

Categoría	Servicio GCP	Descripción Técnica / Capacidades	Ventajas Clave	Casos de Uso / Integraciones Típicas
Plataforma central de IA	**Vertex AI**	Plataforma unificada para entrenamiento, inferencia, monitoreo y despliegue de modelos ML y GenAI. Gestiona todo el ciclo de vida MLOps y LLMOps.	• Integración completa con BigQuery, Dataflow y GKE • Incluye Vertex AI Studio, Model Garden y Pipelines. • Compatible con frameworks open source (TensorFlow, PyTorch, JAX).	Entrenamiento y despliegue de modelos personalizados; pipelines MLOps; inferencia escalable.
Modelos Generativos / LLMs	**Vertex AI Generative Models (Gemini, Imagen, Codey, Chirp, MusicLM)**	Modelos generativos nativos de Google (texto, imagen, código, voz y música). Gemini 1.5 Pro/MultiModal disponible vía API.	• Modelos optimizados y entrenados en la infraestructura de Google. • Integración nativa con Vertex AI Agent Builder y Search.	Chatbots, copilots empresariales, generación de texto, imágenes, código o resúmenes contextuales.
Construcción de agentes y RAG pipelines	**Vertex AI Agent Builder (antes Conversational AI / Gen App Builder)**	Servicio para crear agentes conversacionales y RAG pipelines sin código o low-code. Conecta fuentes de datos (Docs, GCS, BigQuery, Websites) con modelos LLM.	• Pipeline RAG gestionado (retriever + reasoning). • No requiere infraestructura adicional. • Soporte a LangChain y LlamaIndex SDK.	Chatbots empresariales, asistentes internos, motores de búsqueda semántica, QA corporativos.
Búsqueda semántica y RAG	**Vertex AI Vector Search**	Servicio administrado de búsqueda de vectores (embeddings). Optimizado para LLMs, escalable y con baja latencia.	• Indexación automática y sharding gestionado. • Integración directa con BigQuery y LangChain. • Seguridad IAM y cifrado por defecto.	RAG pipelines, context retrieval, sistemas de recomendación semántica.
Modelos preentrenados de visión, texto, traducción, voz	**Cloud AI APIs (Vision, Natural Language, Translation, Speech, Video Intelligence)**	APIs clásicas de IA de Google, totalmente administradas, listas para usar.	• Sin necesidad de entrenamiento. • Alto rendimiento y escalabilidad global. • Integración REST/gRPC directa.	OCR, análisis de sentimientos, detección de objetos, traducción, transcripción.
Modelos de código e ingeniería	**Codey API / Gemini for Code (Vertex AI Studio)**	Modelos LLM especializados en generación y explicación de código, integración con VS Code y Colab.	• Generación de código multi-lenguaje. • Refactorización automática. • Documentación asistida.	Copilots para equipos de desarrollo, QA automation, data engineering.
Datos y pipelines ML	**BigQuery ML**, **Dataflow ML**, **Dataproc**, **AI Platform Notebooks**	Entrenamiento y predicción directamente desde BigQuery y flujos ETL. Soporte a TensorFlow, PyTorch, Scikit-Learn.	• Entrenamiento in-database. • Escalabilidad automática. • Integración con Vertex AI Pipelines.	Analítica predictiva, modelos tabulares, scoring en tiempo real.
Infraestructura optimizada para IA	**A2 / A3 GPU VMs**, **TPU v4 / v5e**, **GKE Autopilot**	Infraestructura gestionada con aceleradores NVIDIA y TPU. Compatible con Vertex AI y Kubernetes.	• Escalabilidad automática. • Compatibilidad con frameworks DL. • Optimización de costos por segundo.	Entrenamiento e inferencia LLMs, visión, multimodalidad.
MLOps / LLMOps	**Vertex AI Pipelines**, **Vertex AI Model Monitoring**, **Vertex AI Feature Store**, **Model Registry**	Orquestación, versionamiento y monitoreo de modelos.	• CI/CD integrado con Cloud Build. • Drift detection y auditabilidad. • Soporte a MLflow y Kubeflow.	Gobierno y trazabilidad de modelos, auditorías de cumplimiento, reproducibilidad.
Gobernanza y seguridad	**Vertex AI Privacy & Security Layer**, **IAM**, **VPC Service Controls**, **Cloud KMS**	Seguridad de modelos y datos en entornos AI. Control de acceso granular e integración con políticas Zero Trust.	• Aislamiento por proyecto y política. • Cifrado automático. • Integración con Cloud Audit Logs.	Cumplimiento GDPR/ISO/NIST, privacidad de datos, gobernanza AI.

Opciones en GCP

Soluciones de almacenamiento en GCP

Google Cloud Platform (GCP) ofrece soluciones de almacenamiento altamente flexibles y seguras, diseñadas para manejar grandes volúmenes de datos con eficiencia y confiabilidad. Las opciones incluyen almacenamiento en bloques, objetos y archivos, lo que permite a las organizaciones elegir el tipo más adecuado según sus necesidades específicas. Además, GCP garantiza alta disponibilidad y durabilidad de los datos, lo que lo convierte en una opción ideal para aplicaciones de inteligencia artificial que requieren acceso rápido y constante a conjuntos masivos de datos.

Seguridad en la nube

La seguridad en GCP se basa en un enfoque integral que incluye múltiples capas de protección para salvaguardar tanto los datos como las aplicaciones. Esto abarca desde cifrado en tránsito y en reposo, políticas de acceso estrictas mediante Identity and Access Management (IAM), hasta detección avanzada de amenazas con inteligencia artificial. Además, GCP cumple con múltiples certificaciones internacionales de seguridad y privacidad, asegurando que las organizaciones puedan operar con confianza en entornos regulados.

Escalabilidad de aplicaciones

GCP proporciona una infraestructura altamente escalable que permite que las aplicaciones de inteligencia artificial se ajusten automáticamente a las fluctuaciones en la demanda de usuarios y volumen de datos. Gracias a servicios como Google Kubernetes Engine y Auto Scaling, las aplicaciones pueden manejar picos de tráfico sin comprometer el rendimiento. Esta capacidad garantiza una experiencia de usuario óptima y eficiencia en costos, ya que se utiliza únicamente la capacidad necesaria en cada momento.

Integración con herramientas open source y despliegue de soluciones LLM/RAG/GEN AI en GCP

Integración con tecnologías open source

GCP facilita la integración sencilla con diversas herramientas open source que potencian el desarrollo tecnológico.

Soporte para IA generativa

GCP soporta arquitecturas avanzadas para el despliegue de soluciones de inteligencia artificial generativa.

Implementación de recuperación aumentada (RAG)

GCP permite la implementación eficiente de sistemas de recuperación aumentada para mejorar el acceso a información.

Integración con herramientas open source y despliegue de soluciones LLM/RAG/GEN AI en GCP

Área	Servicios GCP Relevantes	Integraciones Open Source Compatibles	Descripción Técnica / Casos de Uso Clave
Orquestación y Frameworks de RAG / LLM	**Vertex AI Pipelines**, **Vertex AI Agent Builder**, **GKE Autopilot**, **Cloud Functions**, **Cloud Run**	• **LangChain** (orquestación de flujos RAG y agentes) • **LlamaIndex** (retrieval & data connectors) • **PromptFlow (OSS)** y **Ray Serve** (para inference y agent orchestration) • **Semantic Kernel (Microsoft)** interoperable vía APIs	Permite construir agentes LLM y pipelines RAG con Vertex AI y servicios serverless. LangChain y LlamaIndex se integran directamente con Vertex AI APIs y Vector Search. Ideal para prototipado rápido o despliegue gestionado sin overhead de infraestructura.
Modelos de lenguaje y repositorios	**Vertex AI Model Garden**, **Vertex AI Generative Models**, **AI Platform Custom Jobs**, **GKE / Compute Engine**	• **Hugging Face Transformers / Diffusers** • **PyTorch / TensorFlow / JAX** • **vLLM**, **TGI (Text Generation Inference)** • **PEFT / LoRA / Deepspeed / Accelerate**	Vertex AI Model Garden aloja modelos propios y open source (Gemma, Llama, Mistral, Falcon). Permite fine-tuning y serving en GPUs A100/H100 o TPUs v5e. TGI o vLLM se usan para servir modelos personalizados en GKE o Vertex AI Endpoints.
Almacenamiento y Recuperación (RAG Data Layer)	**Vertex AI Vector Search**, **BigQuery**, **Cloud Storage (GCS)**, **Firestore**, **Cloud SQL**	• **Pinecone**, **Weaviate**, **Milvus**, **FAISS** (conectores LangChain/LlamaIndex) • **Redis Vector / pgvector** • **Chroma**	GCP soporta RAG pipelines combinando Vertex AI Vector Search (servicio administrado) con fuentes personalizadas. Los embeddings se pueden generar con Gemini Embeddings API o Hugging Face. Integración directa con LangChain retrievers y connectors.
Entrenamiento, Fine-tuning e Inferencia	**Vertex AI Training / Custom Jobs**, **GKE**, **Compute Engine (A2, A3, TPU v5e)**	• **Hugging Face Transformers**, **Deepspeed**, **Accelerate**, **PEFT/LoRA**, **TensorRT**, **vLLM**, **TGI**	Vertex AI Training Jobs ejecuta fine-tuning distribuido en GPUs o TPUs. Inferencia puede realizarse en Vertex AI Endpoints (autoscaling) o GKE Autopilot (TGI/vLLM). Compatible con Hugging Face Hub y Ray para entrenamiento distribuido.
MLOps / LLMOps y CI/CD	**Vertex AI Pipelines**, **Vertex AI Model Registry**, **Cloud Build**, **Cloud Deploy**, **Artifact Registry**	• **MLflow**, **Kubeflow on GKE**, **Airflow**, **Metaflow**, **Weights & Biases**, **DVC**	GCP provee pipelines CI/CD nativos con integración a MLflow y Kubeflow. Permite versionamiento, rastreo y despliegue reproducible de modelos LLM. Integración fluida con Terraform o IaC para infra reproducible.
Despliegue de Aplicaciones GenAI (Serving)	**Vertex AI Endpoints**, **Cloud Run**, **GKE Autopilot**, **API Gateway**, **Cloud Load Balancing**	• **FastAPI**, **Flask**, **LangServe**, **Docker / Helm / ArgoCD** • **Streamlit / Gradio** (para UI) • **Terraform / Pulumi** (Infra as Code)	Despliegues serverless con Cloud Run o contenedores gestionados en GKE. Vertex AI Endpoints permiten inferencia con modelos Gemini o personalizados. LangServe o FastAPI facilitan APIs RESTful RAG/LLM en producción.
Observabilidad, Seguridad y Gobernanza	**Cloud Monitoring**, **Cloud Logging**, **Cloud Audit Logs**, **Vertex AI Model Monitoring**, **Security Command Center**, **IAM / VPC Service Controls**	• **Prometheus / Grafana**, **OpenTelemetry**, **Great Expectations** (data validation) • **WhyLabs**, **EvidentlyAI** (drift detection)	GCP integra observabilidad nativa con Prometheus y Cloud Monitoring. Vertex AI Model Monitoring detecta drift de datos y calidad de inferencia. Políticas IAM garantizan aislamiento de proyectos y cumplimiento.
Integración con ecosistema de datos y ETL/ELT	**BigQuery**, **Dataflow**, **Dataproc**, **Pub/Sub**, **Looker**	• **Apache Beam**, **Airbyte**, **dbt**, **Kafka Connect**, **Pandas / Spark**	Conector directo de BigQuery con LangChain y LlamaIndex. Dataflow permite preparar datos para RAG a gran escala. Ideal para pipelines de datos + embeddings + inferencia.

BSG Institute

Ejemplo práctico: Desplegando una solución LLM en Microsoft Azure

Recursos adicionales

Bibliografía recomendada y recursos online

Referencias Clave

- Marr, B. (2020). *Artificial Intelligence in Practice: How 50 Successful Companies Used AI and Machine Learning to Solve Problems*. Wiley.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
- Dean, J. (2018). *Machine Learning on Google Cloud Platform: Practical Solutions From Data Science Experts*. O'Reilly Media.
- Shapiro, S. (2019). *Cloud Computing: Concepts, Technology & Architecture*. Prentice Hall.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Zhang, C., & Ma, Y. (2019). *Ensemble Machine Learning: Methods and Applications*. Springer.
- Kelleher, J. D., & Tierney, B. (2018). *Data Science and Artificial Intelligence: A Guide for Business and Technology Leaders*. CRC Press.
- Hohpe, G. (2017). *Cloud Strategy*. O'Reilly Media.
- Dastin, J. (2020). *AI and Cloud Computing: Convergence and Opportunities*. Pearson.
- Chollet, F. (2018). *Deep Learning with Python*. Manning Publications.

Recursos en Línea

- Coursera (https://www.coursera.org) – Cursos sobre inteligencia artificial y computación en la nube.
- Google Cloud AI and Machine Learning Products (https://cloud.google.com/products/ai)
- AWS Machine Learning (https://aws.amazon.com/machine-learning/)
- edX (https://www.edx.org) – Programas educativos sobre AI y cloud computing.
- Towards Data Science (https://towardsdatascience.com) – Artículos y tutoriales sobre IA y tecnologías cloud.

Conclusión

Importancia de infraestructuras escalables

El diseño de infraestructuras escalables garantiza que los modelos de lenguaje funcionen eficientemente bajo alta demanda.

Seguridad en la nube

Mantener infraestructuras seguras es crucial para proteger datos y asegurar la fiabilidad de los modelos en la nube.

Aplicación de soluciones efectivas

Este curso ofrece fundamentos para implementar soluciones prácticas en plataformas tecnológicas líderes.